



Final Project Statistica Fortis

Analisis dan prediksi Job Satisfaction

FIKRI HADYAN KUSUMA / PROJECT MANAGER

FARIS RAMADHAN / DATA SCIENTIST

DAAN ZHAFRULLAH / DATA ANALYST

MUHAMMAD IHSAN / DATA ENGINEER

Background

Job satisfaction adalah perasaan seseorang terhadap pekerjaannya berdasarkan evaluasinya terhadap pekerjaannya. Job satisfaction adalah salah satu faktor penting dalam sebuah perusahaan karena:

Karyawan dengan job satisfaction tinggi:

- 🏆 Bekerja lebih baik
- 🤝 Lebih setia terhadap perusahaan
- ★ Menunjukkan perilaku membantu karyawan lain, perusahaan, dan juga bekerja melebihi ekspektasi

Tujuan kami:

- 🔍 Mencari tahu faktor yang berhubungan dengan job satisfaction
- 📊 memprediksi job satisfaction

Dashboard



Gambaran umum dataset

Avg. Job Performance

3,15


Avg. Job Satisfaction

2,73


Total Employee

4.410


Gender Proportion




Employee Proportion by Education




Employee Porportion by Department




Job Satisfaction Percentage each Department



Employee Count each Job Role



Dashboard




Link dashboard: <https://lookerstudio.google.com/reporting/73336961-3554-43c5-8548-c1b582350591>

EDA & Insight

Dataset kami berisi 4410 data survei karyawan dengan 29 fitur, yaitu

```
RangeIndex: 4410 entries, 0 to 4409
Data columns (total 28 columns):
 #   Column              Non-Null Count  Dtype
---  -
 0   Age                 4410 non-null   int64
 1   Attrition           4410 non-null   object
 2   BusinessTravel      4410 non-null   object
 3   Department          4410 non-null   object
 4   DistanceFromHome    4410 non-null   int64
 5   Education           4410 non-null   int64
 6   EducationField       4410 non-null   object
 7   EmployeeCount       4410 non-null   int64
 8   EmployeeID          4410 non-null   int64
 9   Gender              4410 non-null   object
10   JobLevel            4410 non-null   int64
11   JobRole             4410 non-null   object
12   MaritalStatus       4410 non-null   object
13   MonthlyIncome       4410 non-null   int64
14   NumCompaniesWorked  4391 non-null   float64
15   PercentSalaryHike   4410 non-null   int64
16   StandardHours       4410 non-null   int64
17   StockOptionLevel    4410 non-null   int64
18   TotalWorkingYears   4401 non-null   float64
19   TrainingTimesLastYear 4410 non-null   int64
20   YearsAtCompany      4410 non-null   int64
21   YearsSinceLastPromotion 4410 non-null   int64
22   YearsWithCurrManager 4410 non-null   int64
23   EnvironmentSatisfaction 4385 non-null   float64
24   JobSatisfaction     4390 non-null   float64
25   WorkLifeBalance     4372 non-null   float64
26   JobInvolvement      4410 non-null   int64
27   PerformanceRating   4410 non-null   int64
dtypes: float64(5), int64(16), object(7)
```

EDA & Insight




Mayoritas data memiliki distribusi right skewed

Beberapa variabel seperti "PercentSalaryHike"

cenderung lebih merata, sementara yang lainnya seperti

"TrainingTimesLastYear" sangat miring ke kanan

EDA & Insight



Beberapa kolom seperti
monthlyincome,
totalworkingyears,
trainingtimeslastyear,
stockoptionlevel,
yearswithcurrmanager,
yearsatcompany memiliki
outliers yang perlu ditangani

Handling Outlier

```
<class 'pandas.core.frame.DataFrame'>
Index: 4041 entries, 0 to 4409
Data columns (total 26 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Age                                    4041 non-null   int64
1   Attrition                            4041 non-null   object
2   BusinessTravel                        4041 non-null   object
3   Department                            4041 non-null   object
4   DistanceFromHome                     4041 non-null   int64
5   Education                             4041 non-null   int64
6   EducationField                        4041 non-null   object
7   EmployeeID                           4041 non-null   int64
8   Gender                                4041 non-null   object
9   JobLevel                              4041 non-null   int64
10  JobRole                               4041 non-null   object
11  MaritalStatus                         4041 non-null   object
12  MonthlyIncome                         4041 non-null   int64
13  NumCompaniesWorked                   4041 non-null   float64
14  PercentSalaryHike                    4041 non-null   int64
15  StockOptionLevel                     4041 non-null   int64
16  TotalWorkingYears                    4041 non-null   float64
17  TrainingTimesLastYear                 4041 non-null   int64
18  YearsAtCompany                        4041 non-null   int64
19  YearsSinceLastPromotion               4041 non-null   int64
20  YearsWithCurrManager                  4041 non-null   int64
21  EnvironmentSatisfaction               4041 non-null   float64
22  JobSatisfaction                       4041 non-null   float64
23  WorkLifeBalance                       4041 non-null   float64
24  JobInvolvement                        4041 non-null   int64
25  PerformanceRating                     4041 non-null   int64
dtypes: float64(5), int64(14), object(7)
memory usage: 852.4+ KB
```

Terdapat total 369 data outlier yang dibuang, sehingga dari sebelumnya terdapat 4409 data menjadi 4041 data

Outlier yang Dihapus:

NumCompaniesWorked (3.54% outlier): Dihapus karena persentase rendah, sehingga penghapusan tidak berdampak signifikan pada jumlah data.

TotalWorkingYears (4.23% outlier): Juga dihapus untuk alasan serupa.

Outlier yang Disimpan:

MonthlyIncome (7.76% outlier): Dipertahankan karena dapat merepresentasikan gaji sangat tinggi yang relevan dalam analisis.

TrainingTimesLastYear (15.98% outlier): Dipertahankan karena data pelatihan yang tinggi mungkin mencerminkan kebijakan pelatihan tertentu.

Pre-processing - Data Cleansing

Fitur - fitur yang terdapat missing value yaitu :

EnvironmentSatisfaction 25

JobSatisfaction 20

WorkLifeBalance 38

NumCompaniesWorked 19

TotalWorkingYears 9

Data Hilang

Dataset tidak memiliki data yang duplikat

Data Duplikat

- Missing value pada fitur EnvironmentSatisfaction, JobSatisfaction, dan WorkLifeBalance dapat ditangani dengan mengisi menggunakan nilai modus, karena data bersifat kategorikal. Sedangkan untuk fitur NumCompaniesWorked dan TotalWorkingYears, missing value dapat ditangani dengan mengisi menggunakan nilai median karena berdasarkan visualisasi histogram, distribusi data cenderung tidak normal dan untuk menghindari pengaruh outlier.
- Setelah itu dilakukan pengecekan data duplikat dan tidak ditemukan adanya data duplikat.

Discard Feature

```
general_data.drop(columns=['EmployeeCount', 'StandardHours', 'Over18'], inplace=True)
```

Fitur EmployeeCount, StandardHours, dan Over18 dibuang, karena memiliki data dengan nilai yang sama sehingga tidak berpengaruh signifikan terhadap model.

- EmployeeCount:

Jika semua baris memiliki nilai yang sama (misalnya, selalu 1), fitur ini tidak memberikan informasi baru kepada model karena tidak ada variasi untuk dipelajari.

- StandardHours:

Jika setiap karyawan memiliki jam kerja yang sama (misalnya, selalu 40 jam/minggu), fitur ini juga tidak menambah nilai prediktif bagi model.

- Over18:

Jika semua karyawan berusia lebih dari 18 tahun (nilai selalu "Yes" atau "1"), fitur ini hanya memberikan informasi yang konstan dan tidak memengaruhi hasil prediksi.

Data Transformation

```
from sklearn.preprocessing import OneHotEncoder
categorical_features = [
    'Attrition',
    'BusinessTravel',
    'Department',
    'EducationField',
    'Gender',
    'JobRole',
    'MaritalStatus'
]

encoder = OneHotEncoder(drop='first', sparse_output=False)
encoded_data = encoder.fit_transform(merged_data[categorical_features])
encoded_df = pd.DataFrame(encoded_data, columns=encoder.get_feature_names_out(categorical_features))
encoded_df.index = merged_data.index
merged_data_encoded = pd.concat([merged_data.drop(columns=categorical_features), encoded_df], axis=1)
merged_data_encoded.isna().sum()
```

Mengubah fitur - fitur kategorik menjadi numerik pada dataset gabungan

1. Mendefinisikan Fitur Kategorikal:

memilih fitur-fitur kategorikal seperti Attrition, BusinessTravel, dll.

2. Menggunakan OneHotEncoder:

drop='first': Menghindari masalah multikolinearitas dengan membuang satu kategori dari setiap fitur.

sparse_output=False: Menghasilkan array yang bukan dalam format sparse matrix, melainkan dalam format array biasa (NumPy).

3. Transformasi Data:

Fitur kategorikal diubah menjadi bentuk numerik (one-hot encoded).

4. Membuat DataFrame Baru:

Data hasil encoding diubah menjadi DataFrame dengan nama kolom sesuai dengan kategori.

5. Menggabungkan Dataset:

Data hasil encoding digabungkan kembali ke dataset awal setelah fitur kategorikal asli dihapus.

6. Memeriksa Missing Values:

Baris terakhir, merged_data_encoded.isna().sum(), memeriksa jumlah nilai kosong (missing values) di dataset gabungan.

Age	0
DistanceFromHome	0
Education	0
EmployeeID	0
JobLevel	0
MonthlyIncome	0
NumCompaniesWorked	0
PercentSalaryHike	0
StockOptionLevel	0
TotalWorkingYears	0
TrainingTimesLastYear	0
YearsAtCompany	0
YearsSinceLastPromotion	0
YearsWithCurrManager	0
EnvironmentSatisfaction	0
JobSatisfaction	0
WorkLifeBalance	0
JobInvolvement	0
PerformanceRating	0
Attrition Yes	0

BusinessTravel_Travel_Frequently	0
BusinessTravel_Travel_Rarely	0
Department_Research & Development	0
Department_Sales	0
EducationField_Life Sciences	0
EducationField_Marketing	0
EducationField_Medical	0
EducationField_Other	0
EducationField_Technical Degree	0
Gender_Male	0
JobRole_Human Resources	0
JobRole_Laboratory Technician	0
JobRole_Manager	0
JobRole_Manufacturing Director	0
JobRole_Research Director	0
JobRole_Research Scientist	0
JobRole_Sales Executive	0
JobRole_Sales Representative	0
MaritalStatus_Married	0
MaritalStatus_Single	0

Output yang dihasilkan menunjukkan 0 di setiap kolom, karena Output 0 menunjukkan bahwa dataset sudah bersih dan tidak ada nilai kosong setelah transformasi.

Modeling

Hyperparameter Tuning (CV=5)

Model	Hyperparameter
Decision Tree	'criterion': 'gini', 'max_depth': None, 'min_samples_leaf': 1, 'min_samples_split': 2
Random Forest	'criterion': 'gini', 'max_depth': 20, 'min_samples_leaf': 1, 'min_samples_split': 5, 'n_estimators': 100
SVM Kernel Poly	'C': 10, 'degree': 4, 'gamma': 'scale', 'kernel': 'poly'
KNN	'metric': 'manhattan', 'n_neighbors': 3, 'weights': 'distance'
XGBOOST	'colsample_bytree': 1.0, 'learning_rate': 0.2, 'max_depth': 7, 'n_estimators': 200, 'subsample': 0.8

Modeling

Training

Model	Accuracy
Decision Tree	0,87
Random Forest	0,93
SVM Kernel Poly	0,94
KNN	0,93
XGBOOST	0,91

Modeling

Testing

Model	Accuracy	Precision	Recall	F1-Score
Decision Tree	0.98	0.98	0.98	0.98
Random Forest	0.98	0.98	0.98	0.98
SVM Kernel Poly	0.97	0.97	0.97	0.97
KNN	0.98	0.98	0.98	0.98
XGBOOST	0.97	0.97	0.97	0.97

Modeling

Model yang dipilih:
Random forest

Alasan memilih random forest:


- **Performa saat latihan (0,93) dan tes (0,98) cukup baik**
- **Model cenderung reliabel**

Metric:

Akurasi, berarti seberapa akurat model dalam memprediksi tingkat job satisfaction

Modeling

Mencari faktor yang berhubungan dengan job satisfaction dengan decision tree



Recommendation

- 💰 Perusahaan bisa menetapkan gaji di sekitar 63 ribu rupee sebagai nominal yang cukup untuk meningkatkan Job Satisfaction karyawan, setelah gaji 63 ribu perusahaan bisa fokus pada hal lain untuk meningkatkan job satisfaction karyawan.
- 🌟 Usahakan job satisfaction karyawan berada di level sangat tinggi untuk mendapatkan Performance yang tinggi dan attrition yang rendah
- 🔄 Prediksi bisa dilakukan secara berkala atau saat dibutuhkan saja, karenanya model bisa dijalankan secara lokal atau bisa menggunakan Apache Airflow, atau jika ingin real time dalam bentuk dashboard bisa menggunakan streamlit. Berikut adalah contoh dashboard prediksi yang kami buat: hr-analytics-case-study.streamlit.app/

Dashboard prediksi

[Fork](#)  

Masukkan Data

Age

0,00  

Attrition

Yes 

Business Travel

Travel Rarely 

Department

Sales 

Distance From Home

0,00  

Education

0,00  

Education Field

Life Sciences 



TERIMA KASIH